



REDES NEURONALES

GRETHE — NAGELBERG — GRABINA

PROBLEMA




ATT 99 DEF ∞




Lil Uzi Vert

007 6x01 / 021

SOLUCIÓN



Entrada: 2 – Salida: 1
Entrenamiento supervisado



IMPLEMENTACION


- X Octave
- X Git
- X Teóricas de la cátedra

Perceptron simple (AND) → Perceptron multicapa
(XOR) → Simulación del terreno

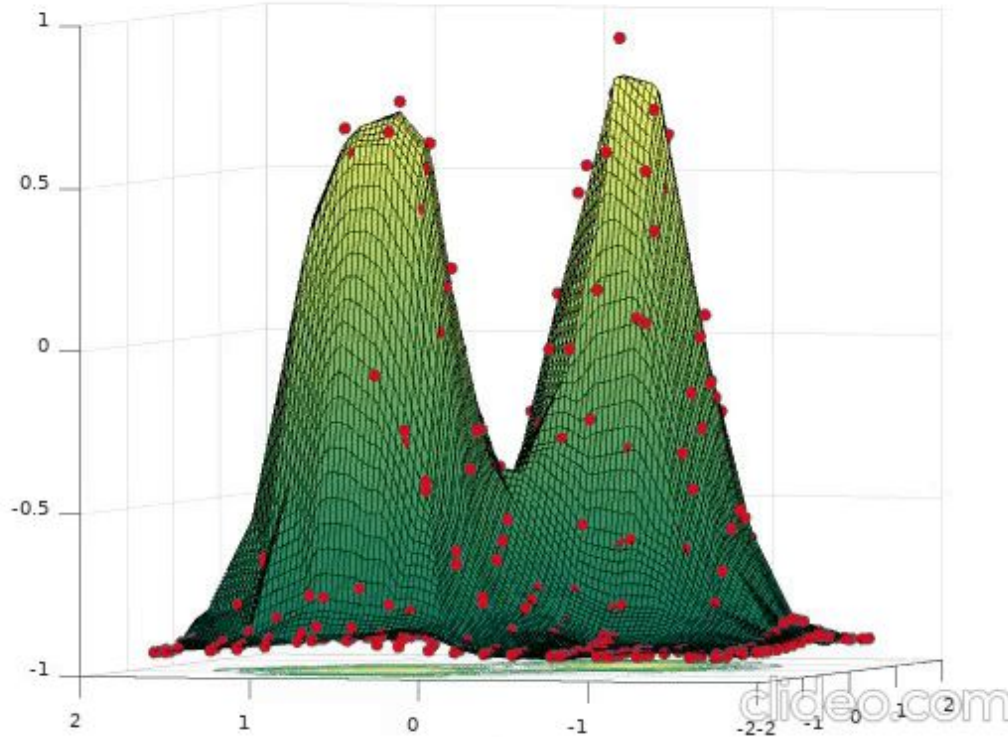
```
▼ TP2
  ▼ activation_functions
    /* hyp_tan.m
    /* hyp_tan_d.m
    /* hyp_tan_inv.m
    /* normalize.m
    /* sigmoid_exp.m
    /* sigmoid_exp_d.m
    /* sigmoid_exp_inv.m
    /* batch_main.m
    /* batch_trainer.m
    /* configuration.m
    /* data_init.m
    /* get_random_patterns.m
    /* incremental_trainer.m
    /* load_terrain.m
    /* main.m
    /* plot_terrain.m
    /* plot_terrain_2.m
    /* predict.m
    terrain02.data
```

TERRENO REAL

Mordor



TERRENO GENERADO



60% datos
Arq. 50-50-50-50
 $E < 0.0002$
7000 Epochs

¿COMO LO HICIMOS?

ENTRENAMOS LA RED CON

Batch

Error de corte: 0.0002 (o largo plazo)

Función Tangencial

Beta = 1.0

ETA = 0.0005

Puntos específicos añadidos para precisión (los mas elevados)

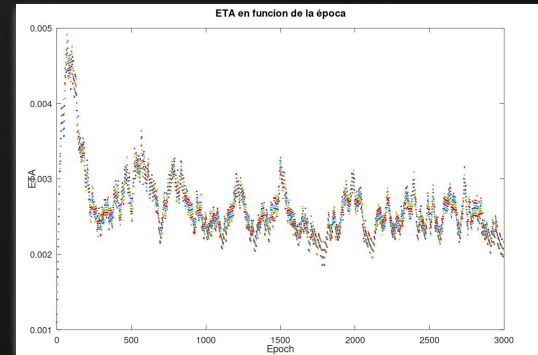



Sin optimizaciones (ETA adaptativo, Momentum)

Arquitectura (50 50 50 50)

RESULTADOS DE LAS VARIACIONES DE PARÁMETROS

METRICAS

ECM, EPOCHS, GENERALIZACION



PARAMETROS FIJOS

Batch

Error de corte: 0.0005

Función Tangencial

Beta = 1.0

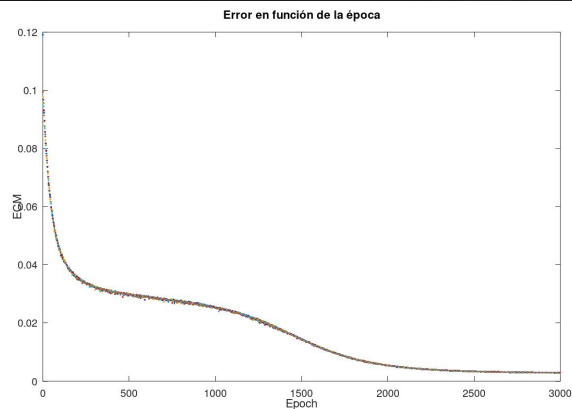

ETA = 0.0005

Sin puntos específicos añadidos para precisión


Sin optimizaciones (ETA adaptativo, Momentum)

Arquitectura (50 50 50 50)


COMPARATIVA: ARQUITECTURA NODOS ~ 1 CAPA



200 NEURONAS





120 NEURONAS




60 NEURONAS


COMPARATIVA: ARQUITECTURA NODOS ~ 1 CAPA



200 NEURONAS




120 NEURONAS




60 NEURONAS


COMPARATIVA: ARQUITECTURA CAPAS OCULTAS 3000 EPOCH



[50 50 50 50 50]
5 CAPAS



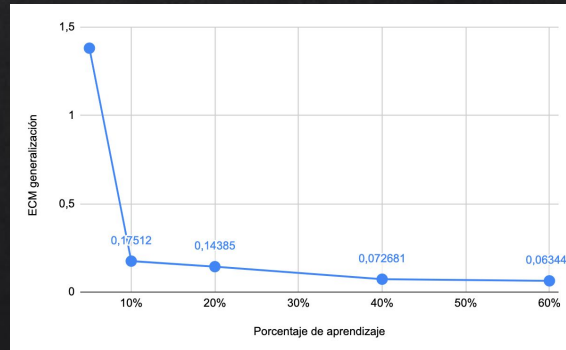
[50 50 50]
3 CAPAS




[50]
1 CAPA

COMPARATIVA: % DE DATOS APRENDIDOS


PORCENTAJE DE APRENDIZAJE	ECM GENERALIZACIÓN
5%	1.3813
10%	0.17512
20%	0.14385
40%	0.072681
60%	0.063448




COMPARATIVA: % DE DATOS APRENDIDOS ERROR TRIDIMENSIONAL



60%




20%




5%

COMPARATIVA: % DE DATOS APRENDIDOS: GENERACIÓN


60%




20%



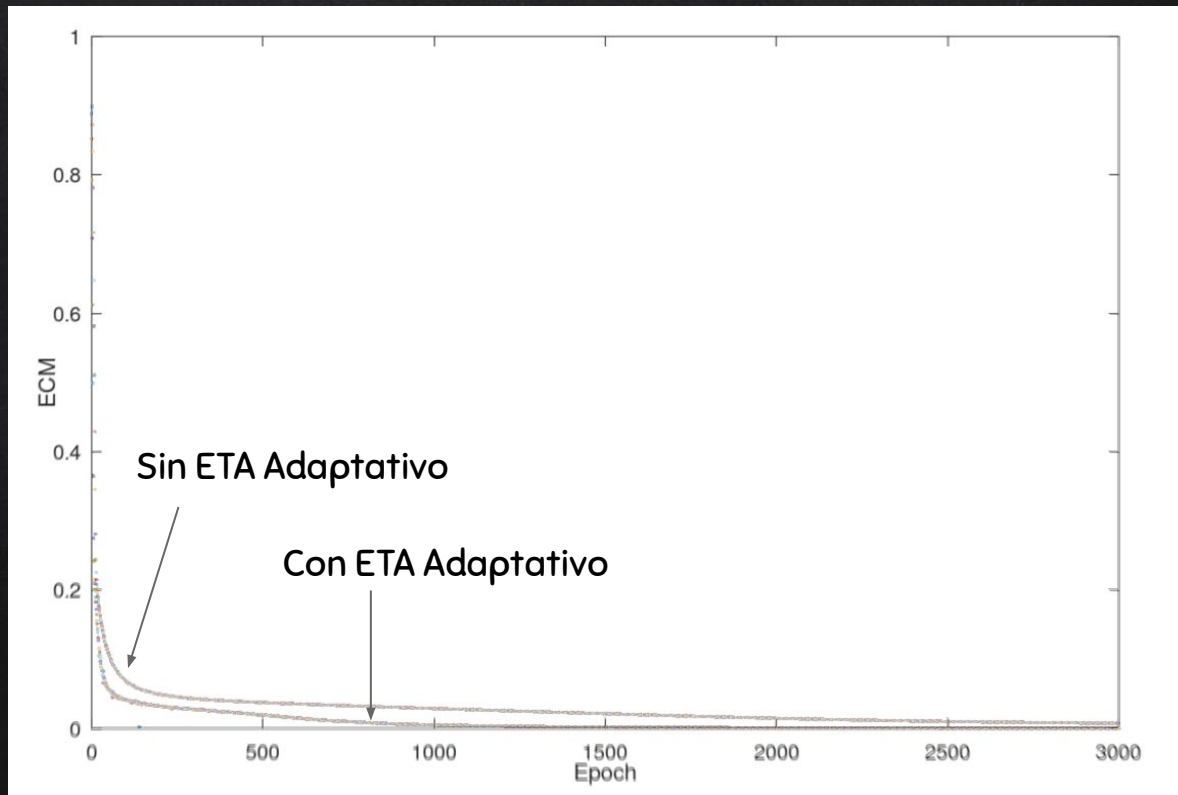
10%



5%



COMPARATIVA: ETA ADAPTATIVO



BATCH

ARQUITECTURA [50 50]

ETA INICIAL DE 0.001

CONSTANTE A = 0.0001

CONSTANTE B = 0.05

ETA MÍNIMO = 0.0001


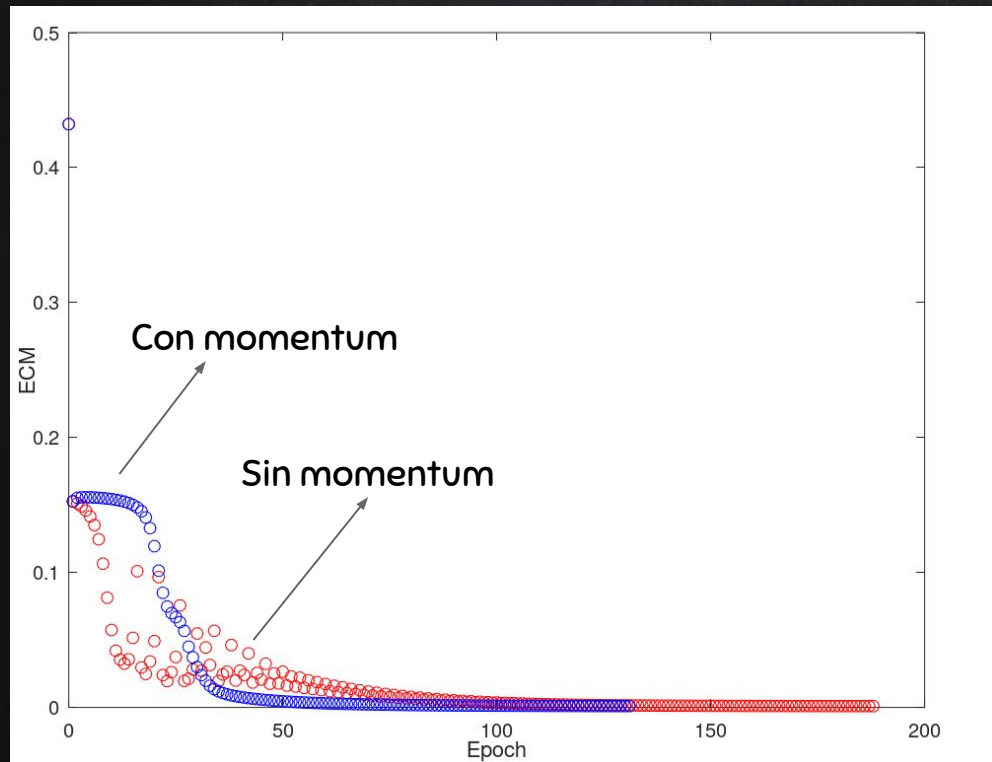
ETA MÁXIMO = 0.005

COMPARATIVA: MOMENTUM


BATCH

ARQUITECTURA [50 50 50 50]

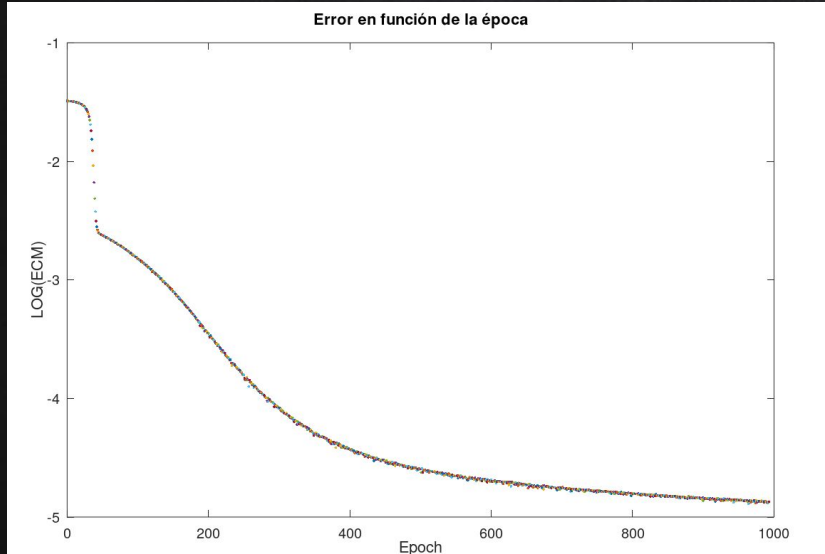
MOMENTUM VALUE 0.5




Minimo local



COMPARATIVA: EXP vs TAN



Exponencial




Tangencial


Beta = 1.5

COMPARATIVA: EXP vs TAN

EVOLUCIÓN DEL APRENDIZAJE (ETA)




Exponencial




Tangencial

Beta = 1.5

COMPARATIVA: BATCH vs INCREMENTAL



ECM = 0.074



ECM = 0.072


BATCH

- FULL DATA
- MEJOR PERFORMANCE


INCREMENTAL

- REAL TIME
- MAS EFICAZ POR TEORIA

COMPARATIVA: BETA CON F. TAN.




BETA = 1.5





BETA = 0.5

EL PROBLEMA DE LAS PUNTAS



COMPARATIVA:

PUNTOS RANDOM VS PUNTOS RANDOM + LAS PUNTAS



CONCLUSIONES

- El comportamiento de la red varía mucho en función a todos los parámetros mencionados, y los valores óptimos de los mismos también dependen de los demás para acelerar la convergencia del error.
- Siguiendo el teorema de aproximación universal (Hornik, Stinchcombe y White), pudimos ver que es posible tener una buena generalización con una única capa oculta de varias neuronas. La cantidad de capas y neuronas por capa fueron determinadas mediante la realización de pruebas empíricas
- Es importante una buena elección de patrones de entrenamiento en zonas donde la función presenta picos o valles porque es la zona donde más error puede ocurrir. En los segmentos lineales, la red aprende más fácilmente que en los picos/valles.
- Las optimizaciones propuestas, lograron mejorar los tiempos de convergencia.
- Respecto a la arquitectura en general, mientras más capas y neuronas utilizamos, obtuvimos mejores resultados.
- A mayor porcentaje de datos aprendidos, mejor nivel de generalización.

GRACIAS!

Preguntas?